

Chapter 4: Spark SQL & Dataframe

Ex 1: Fifa2018

Cho tập tin Fifa2018_dataset.csv

Yêu cầu:

- 1. Đọc tập tin Fifa2018_ dataset.csv vào fifa df.
- 2. In schema của fifa_df. Hiển thị 2 dòng đầu tiên của dữ liệu. Cho biết dữ liệu có bao nhiêu dòng?
- 3. Tạo view 'fifa table' từ fifa df
- 4. Hãy thực hiện SQL Query để lấy cột Age của các vận động viên có Nationality là "Germany" => fifa germany age. Hiển thị 3 dòng đầu của dữ liệu. In thống kê dữ liệu
- 5. Trực quan hóa dữ liệu fifa_germany_age. Nhận xét biểu đồ.
- 6. Từ fifa_df, cho biết mỗi độ tuổi có bao nhiêu cầu thủ. Độ tuổi trung bình của cầu thủ mỗi quốc gia là bao nhiêu?
- 7. Từ fifa_df, cho biết "Age" nhỏ nhất, "Age" lớn nhất, "Strength" nhỏ nhất, "Strength" lớn nhất
- 8. Liệt kê danh sách các "Club" (duy nhất) theo 2 cách với Dataframe fifa_df và SQL query với fifa table.
- 9. Từ fifa_df, sắp xếp dữ liệu giảm dần theo Age => fifa_df_desc.
- 10. Có bao nhiêu cầu thủ trong "Name" có "Cristiano" theo 2 cách với Dataframe fifa_df và SQL query với fifa table. In tên các cầu thủ này.



```
In [8]: # Show the first 3 observations
    for row in fifa_df.head(2):
        print(row)
        print('\n')
#fifa_df.show(3)
```

Row(_c0=0, Name='Cristiano Ronaldo', Age=32, Photo='https://cdn.sofifa.org/48/1 8/players/20801.png', Nationality='Portugal', Flag='https://cdn.sofifa.org/flag s/38.png', Overall=94, Potential=94, Club='Real Madrid CF', Club Logo='https:// cdn.sofifa.org/24/18/teams/243.png', Value='€95.5M', Wage='€565K', Special=222 8, Acceleration='89', Aggression='63', Agility='89', Balance='63', Ball control ='93', Composure='95', Crossing='85', Curve='81', Dribbling='91', Finishing='9 4', Free kick accuracy='76', GK diving='7', GK handling='11', GK kicking='15', GK positioning='14', GK reflexes='11', Heading accuracy='88', Interceptions='2 9', Jumping='95', Long passing='77', Long shots='92', Marking='22', Penalties ='85', Positioning='95', Reactions='96', Short passing='83', Shot power='94', S liding tackle='23', Sprint speed='91', Stamina='92', Standing tackle='31', Stre ngth='80', Vision='85', Volleys='88', CAM=89.0, CB=53.0, CDM=62.0, CF=91.0, CM= 82.0, ID=20801, LAM=89.0, LB=61.0, LCB=53.0, LCM=82.0, LDM=62.0, LF=91.0, LM=8 9.0, LS=92.0, LW=91.0, LWB=66.0, Preferred Positions='ST LW ', RAM=89.0, RB=61. 0, RCB=53.0, RCM=82.0, RDM=62.0, RF=91.0, RM=89.0, RS=92.0, RW=91.0, RWB=66.0, ST=92.0)

Row(_c0=1, Name='L. Messi', Age=30, Photo='https://cdn.sofifa.org/48/18/player s/158023.png', Nationality='Argentina', Flag='https://cdn.sofifa.org/flags/52.p ng', Overall=93, Potential=93, Club='FC Barcelona', Club Logo='https://cdn.sofi fa.org/24/18/teams/241.png', Value='€105M', Wage='€565K', Special=2154, Acceler ation='92', Aggression='48', Agility='90', Balance='95', Ball control='95', Com posure='96', Crossing='77', Curve='89', Dribbling='97', Finishing='95', Free ki ck accuracy='90', GK diving='6', GK handling='11', GK kicking='15', GK position ing='14', GK reflexes='8', Heading accuracy='71', Interceptions='22', Jumping='68', Long passing='87', Long shots='88', Marking='13', Penalties='74', Positioning='93', Reactions='95', Short passing='88', Shot power='85', Sliding tackle='26', Sprint speed='87', Stamina='73', Standing tackle='28', Strength='59', Vision='90', Volleys='85', CAM=92.0, CB=45.0, CDM=59.0, CF=92.0, CM=84.0, ID=1580 23, LAM=92.0, LB=57.0, LCB=45.0, LCM=84.0, LDM=59.0, LF=92.0, LM=90.0, LS=88.0, LW=91.0, LWB=62.0, Preferred Positions='RW ', RAM=92.0, RB=57.0, RCB=45.0, RCM=84.0, RDM=59.0, RF=92.0, RF=92.0, RR=90.0, RS=88.0, RW=91.0, RWB=62.0, ST=88.0)

```
In [9]: # Print the total number of rows
print("There are {} rows in the fifa_df DataFrame".format(fifa_df.count()))
```

There are 17981 rows in the fifa_df DataFrame

```
In [10]: #3. Create a temporary view of fifa_df
fifa_df.createOrReplaceTempView('fifa_table')
```

```
In [11]: # 4.
         # Construct the "query"
         query = '''SELECT Age FROM fifa_table WHERE Nationality == "Germany"'''
         # Apply the SQL "query"
         fifa_germany_age = spark.sql(query)
In [12]: fifa_germany_age.show(3)
         Age
          31
          27
         28
         +---+
         only showing top 3 rows
In [13]: # Generate basic statistics
         fifa_germany_age.describe().show()
         |summary|
                                Age
                               1140
            count
             mean | 24.20263157894737 |
           stddev 4.197096712293752
              min|
                                 16
              max
In [14]: #5.
         # Convert fifa_germany_age to fifa_germany_age_pandas DataFrame
         fifa_germany_age_pandas = fifa_germany_age.toPandas()
```

In [15]: import matplotlib.pyplot as plt

```
In [16]: # Plot the 'Age' density of Germany Players
    fifa_germany_age_pandas.plot(kind='density')
    plt.show()
```



```
0.08 - O.06 - O.02 - O.00 - O.
```

```
In [17]: #6.
fifa_df.groupBy("Age").count().show()
```

```
|Age|count|
  31
       671
  34
       272
  28 | 1051 |
  26
      1202
  27
      1152
  44
          2
  22
      1324
  47
          1
  16
        13
  20|
      1245
  40
         8
  19
      1069
  41
          3 |
         2
  43
        69
  37
  17
       258
  35
       191
  39
        20
  23 | 1394 |
  38|
        36
only showing top 20 rows
```

In [18]: fifa_df.groupBy("Nationality").avg("Age").show()



+	++					
Nationality	avg(Age)					
+	·					
Chad	25.0					
Russia	25.23202614379085					
Paraguay	26.10144927536232					
Senegal	25.046511627906977					
Sweden	25.119565217391305					
Guyana	28.0					
Eritrea	32.0					
Philippines	25.6666666666668					
Fiji	29.0					
Turkey	25.127147766323024					
Iraq	26.0					
Germany	24.20263157894737					
St Kitts Nevis	26.666666666668					
Comoros	27.11111111111111					
Afghanistan	22.0					
Ivory Coast	24.10891089108911					
Sudan	22.5					
France	24.634969325153374					
	24.418367346938776					
Kosovo	23.9375					
++						
only showing top 20 rows						

In [19]: #7.



	+				
	Nationality	min(Age)	max(Age)	min(Strength)	max(Strength)
	Chad	 24	26	73	 79
	Paraguay	18	37	33	91
	Russia	17	37	26	93
	Senegal	18	34	37	94
	Sweden	17	37	21	91
	Guyana	25	34	47	75
	Eritrea	32	32	85	85
	Philippines	22	28	42	76
	Fiji	29	29	57	57
	Turkey	17	39	30	90
	Iraq	21	30	55	86
	Germany	16	36	28	94
	St Kitts Nevis	23	32	32	
	Comoros	•	32	28	82
	Afghanistan			40	58
	Ivory Coast			38	:
	Sudan			41	62
	France			26	:
	Greece				:
	Kosovo	18	33	30	90
-	+				

only showing top 20 rows

```
In [20]: #8.
fifa_df.select("Club").distinct().show()
```



```
Club|
              Palermo|
          Yeovil Town
   1. FC Union Berlin
   Santiago Wanderers
                Carpi|
|Evkur Yeni Malaty...|
           Sagan Tosu
             FC Basel
  Argentinos Juniors
        Karlsruher SC
   Lorca Deportiva CF
      SC Paderborn 07
      Cheltenham Town
|San Lorenzo de Al...|
          SC Freiburg
   SpVgg Unterhaching
|Atletico Nacional...|
|Universidad Católica|
          GFC Ajaccio
            FC Luzern
only showing top 20 rows
```

```
In [21]: query = '''SELECT DISTINCT Club FROM fifa table'''
         # Apply the SQL "query"
         fifa_clubs = spark.sql(query)
         fifa clubs.show()
                      Palermo|
                  Yeovil Town
            1. FC Union Berlin
            Santiago Wanderers
                        Carpi
         |Evkur Yeni Malaty...|
                   Sagan Tosu
                     FC Basel
            Argentinos Juniors
                 Karlsruher SC
            Lorca Deportiva CF
               SC Paderborn 07
               Cheltenham Town
         |San Lorenzo de Al...|
                  SC Freiburg
            SpVgg Unterhaching
         |Atletico Nacional...|
         |Universidad Católica|
                  GFC Ajaccio
                    FC Luzern
         only showing top 20 rows
In [22]:
         fifa df desc = fifa df.orderBy(fifa df["Age"].desc())
In [23]: fifa_df_desc.select("Name", "Age", "Strength").show(3)
             -----+
                  Name | Age | Strength |
         +-----
         |B. Richardson| 47|
                                 47
         | E. El Hadary| 44|
                                 73
              0. Pérez | 44|
         only showing top 3 rows
In [24]:
         #10.
         people_with_Cristiano = fifa_df.where(fifa_df["Name"].contains("Cristiano"))
         people with Cristiano.count()
Out[24]: 3
```

```
In [25]: people_with_Cristiano.select("Name").show()
          ----+
                    Name
          -----+
        |Cristiano Ronaldo|
                Cristiano|
                Cristiano|
        +----+
        query = '''SELECT * FROM fifa_table WHERE Name like "%Cristiano%"'''
In [26]:
        people_with_Cristiano_2 = spark.sql(query)
        people_with_Cristiano_2.count()
Out[26]: 3
In [27]: people_with_Cristiano_2.select("Name").show()
        +----+
                    Name
        +----+
        |Cristiano Ronaldo|
                Cristiano|
                Cristiano|
```